(19)国家知识产权局

(12)发明专利申请

(10)申请公布号 CN 121092907 A
(43)申请公布日 2025.12.09

(21)申请号 202511211592.6

(22)申请日 2025.08.28

(71)申请人 广东工业大学
地址 510006 广东省广州市番禺区小谷围街道广东工业大学

(72)发明人 徐雍 郑楚伟 刘畅 饶红霞 彭慧 叶燕燕 鲁仁全 李军毅

(74)专利代理机构 广东南北知识产权代理事务所(普通合伙) 44918
专利代理师 肖湘漓

(51)Int.Cl.
G06F 18/20(2023.01)
G06N 3/0499(2023.01)
G06F 18/2433(2023.01)
G06N 3/045(2023.01)
G06F 18/10(2023.01)

权利要求书3页 说明书8页 附图3页

(54)发明名称

基于灵敏度分析与异常值处理的低比特大模型量化方法及系统

(57)摘要

本发明提供一种基于灵敏度分析与异常值处理的低比特大模型量化方法,包括利用基于灵敏度分析的层级混合精度量化策略将模型层划分为高、中、低敏感度层,并执行不同的量化操作;利用基于两阶段联合的量化方法进行权重异常值抑制和权重逐层执行量化;进行基于等价变换的激活离群值离线平滑处理。本发明基于灵敏度分析的层级混合精度量化策略识别对量化误差敏感的关键权重,从而在量化过程中采用差异化策略,保留高灵敏度权重的精度并且对低灵敏度权重实施更激进量化,以最小化模型性能损失;两阶段权重量化协同解决异常值与误差累积问题:离线地将量化难度从激活迁移到权重,提高激活量化的友好性,无需在运行时动态检测离群值,避免影响推理速度。

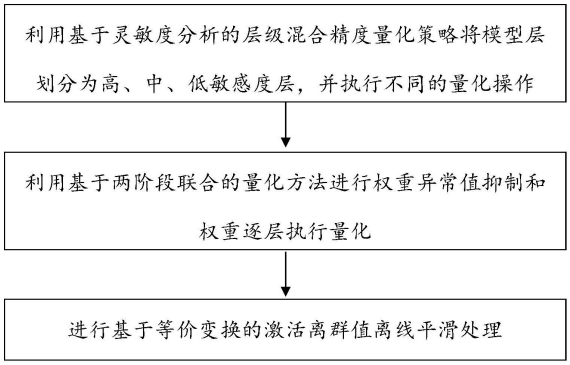

CN 121092907 A

1.基于灵敏度分析与异常值处理的低比特大模型量化方法,其特征在于,包括如下步骤:

S1)、利用基于灵敏度分析的层级混合精度量化策略将模型层划分为高、中、低敏感度层,并执行不同的量化操作;

S2)、利用基于两阶段联合的量化方法进行权重异常值抑制和权重逐层执行量化;

S3)、进行基于等价变换的激活离群值离线平滑处理。

2.根据权利要求1所述的基于灵敏度分析与异常值处理的低比特大模型量化方法,其特征在于:步骤S1)中,利用基于灵敏度分析的层级混合精度量化策略将模型层划分为高、中、低敏感度层,并执行不同的量化操作,具体包括如下步骤:

S11)、选取小型校准输入集X,通过前向传播记录模型各层输入激活与输出;

S12)、对第1层权重矩阵$W_1 \in R^{m\times n}$,定义量化灵敏度$\Delta E \in R^{m\times n}$为原始权重预测值$W_1X$与量化权重预测值$W_1'X$之间的误差,其中,m、n分别为权重矩阵$W_1$的宽和高;

S13)、通过目标函数E(w)在局部点的扰动进行二阶泰勒展开量化灵敏度ΔE,忽略收敛模型的梯度项后得到:

$$\Delta E \approx \frac{1}{2}\delta_w{}^T H \delta_w; \qquad (1)$$

$$s.t.\quad e_q^T \delta_w + w_q - quant(w_q) = 0; \qquad (2)$$

式中,δ_w是权重量化引入的扰动值,H为Hessian矩阵;quant()是量化函数;e_q^T是在位置q为1其余位置为0的单位选择向量;w_q为w的第q个元素;w为模型的权重参数,即量化对象;T表示转置操作;

S14)、采用拉格朗日乘子法构建优化问题,即:

$$L = \frac{1}{2}\delta_w{}^T H \delta_w + \lambda(e_q^T \delta_w + w_q - quant(w_q)); \qquad (3)$$

通过$\frac{\partial L}{\partial \delta_w} = 0$,得到最优扰动:

$$\delta_w = -\frac{w_q - quant(w_q)}{[H^{-1}]_{qq}} H_{:,q}^{-1}; \qquad (4)$$

代入误差公式后,量化灵敏度解析式为:

$$\Delta E = \frac{1}{2}\frac{(w_q - quant(w_q))^2}{[H^{-1}]_{qq}}; \qquad (5)$$

式中,L表示拉格朗日函数;H^{-1}表示Hessian矩阵的逆,$[H^{-1}]_{qq}$表示H^{-1}的q行q列交叉位置的值;$H_{:,q}^{-1}$表示H^{-1}的第q列;

S15)、根据灵敏度评分将模型层划分为高、中、低敏感度层,采用如下量化策略计算缩放因子s和量化后的权重W_q;并通过量化后的权重W_q执行量化,不同的敏感度层采用不同的量化位数;其中:

$$s = \frac{max(W_l) - min(W_l)}{2^b - 1}; \qquad (6)$$

$$W_q = clamp(round(\frac{W_l}{s}), -2^{b-1} + 1, 2^{b-1} - 1); \qquad (7)$$

式中,clamp函数确保值不超出有效范围,round表示执行四舍五入取整操作;b是量化

位数。

3.根据权利要求2所述的基于灵敏度分析与异常值处理的低比特大模型量化方法,其特征在于:步骤S1)中,所述校准输入集X的样本数量要求覆盖模型常见输入分布,Hessian矩阵的计算通过逐层前向传播与梯度回溯实现,忽略模型收敛后的梯度项$g^T\delta_w$,仅保留二阶项以简化计算。

4.根据权利要求2所述的基于灵敏度分析与异常值处理的低比特大模型量化方法,其特征在于:步骤S1)中,所述高、中、低敏感度层的划分阈值基于灵敏度评分的统计分布确定:灵敏度评分前30%的层为高敏感度层,中间40%为中敏感度层,后30%为低敏感度层;所述的clamp函数的取值范围为$(-2^{b-1}+1,2^{b-1}-1)$用于避免量化后权重超出低精度整数的表示范围。

5.根据权利要求1所述的基于灵敏度分析与异常值处理的低比特大模型量化方法,其特征在于:步骤S2)中,两个阶段中的第一个阶段基于旋转不变性进行权重异常值抑制;第二个阶段采用基于逆Hessian矩阵减少层间量化误差。

6.根据权利要求5所述的基于灵敏度分析与异常值处理的低比特大模型量化方法,其特征在于:步骤S2)中,所述的第一个阶段采用随机选取与模型隐藏维度匹配的随机Hadamard矩阵对transformer块中的权重和块间激活进行转换,对于注意力层W_q、W_k、W_v、及MLP层W_{gate}、W_{up}权重矩阵进行前乘$Q^{-1}*diag(\alpha)$;对W_o、W_{down}权重矩阵进行后乘Q,同时将RMSNorm线性部分融合至相邻权重,满足下式,使模型输出保持不变:

$$RMSNorm(X_L)=RMSNorm(X_LQ^T)Q; \quad (8)$$

式中,X_L为输入激活;Q为Hadamard矩阵。

7.根据权利要求5所述的基于灵敏度分析与异常值处理的低比特大模型量化方法,其特征在于:步骤S2)中,所述的第二个阶段通过逐层执行量化,解决每一层的重构问题,对于线性层L的权重W_L、输入激活X_L,目标是找到相对于全精度层输出最小化平方误差的量化权重矩阵$\widehat{W}_L^*$,具体表达式为:

$$\widehat{W}_L^* = argmin_{\widehat{W}_L}||W_LX_L - \widehat{W}_LX_L||_2^2。 \quad (20)$$

8.根据权利要求7所述的基于灵敏度分析与异常值处理的低比特大模型量化方法,其特征在于:步骤S2)中,所述的第二个阶段通过逐层执行量化,具体包括如下步骤:

S221)、初始化量化输出矩阵$Q \in R^{d_{row}\times d_{col}} = 0$,量化误差矩阵$E \in R^{d_{row}\times B} = 0$,B为块的大小;对逆Hessian矩阵$H^{-1}=(2X_LX_L^T+\lambda I)^{-1}$进行Cholesky分解:

$$H^{-1}\leftarrow Cholesky(H^{-1}); \quad (21)$$

其中,λ表示正则化参数;I表示单位矩阵;

S222)、按块大小B遍历权重矩阵的W_L的列;

对当前块内每一列j∈[i,i+B-1]执行:

量化操作:$Q_{:,j}\leftarrow quant(W_{L:,j})$; (22)

误差计算:$E_{:,j-i} \leftarrow \frac{(W_{L:,j}-Q_{:,j})}{[H^{-1}]_{jj}}$; (23)

式中,$Q_{:,j}$为W_L的第j列量化后的权重;$E_{:,j-i}$表示当前块内第(j-i)列的量化误差,i表示分块的起始索引(i=0,B,2B,…);$[H^{-1}]_{jj}$表示逆Hessian矩阵的第j行j列交叉位置的值;

S223)、更新块内权重；

$$W_{L_{:,j:(i+B)}} \leftarrow W_{L_{:,j:(i+B)}} - E_{:,j-i} * H^{-1}_{j,j:(i+B)}; \quad (24)$$

式中，$W_{L:,j:(i+N)}$表示权重矩阵W_L的第j列到第(i+B)列，即当前块内剩余的列；$E_{:,j-i}$表示当前块内第(j-i)列的量化误差；$H^{-1}_{j,j:(i+B)}$表示逆Hessian矩阵的第j行、第j列到(i+B)列的元素；

S224)、更新块间全局权重：

$$W_{:,(i+B):} \leftarrow W_{:,(i+B):} - E * H^{-1}_{i,(i+B):}; \quad (25)$$

式中，$W_{:,(i+B):}$表示第(i+B)列后面的权重块；$H^{-1}_{i,(i+B):}$表示逆Hessian矩阵的第i行、第(i+B)列之后的行向量。

9.根据权利要求1所述的基于灵敏度分析与异常值处理的低比特大模型量化方法，其特征在于：步骤S3)中，进行基于等价变换的激活离群值离线平滑处理，具体包括如下步骤：

S31)、通过校准数据前向推理，统计每个线性层的激活在Channel维度的绝对值最大值$\max(|X_j|)^{\propto}$与权重在C_i维度的绝对值最大值$\max(|W_j|)^{1-\propto}$，计算每通道平滑因子S_j；即：

$$S_j = \frac{max(|X_j|)^{\alpha}}{max(|W_j|)^{1-\alpha}}, j = 1,2,\ldots,C_i; \quad (26)$$

式中，α表示缩放系数；S_j表示第j个通道的平滑因子；X_j表示第j个通道的激活值；W_j表示第j个通道的权重；

S32)、通过将通道平滑因子S_j嵌入前序模块RMSNorm参数，在RMSNorm模块权重中除以S_j；

在W_q、W_k、W_v、W_{gate}、W_{up}的线性层权重中乘以S_j，实现激活离群值向权重的迁移，保持线性层输出与原输出等价，即：

$$Y = (Xdiag(S)^{-1}) \cdot (diag(S)W) = \hat{X}\hat{W}; \quad (27)$$

式中，Y为线性层输出；S为通道平滑因子；X表示该线性层的激活值，W表示该线性层的权重；$\hat{X}$和$\hat{W}$分别表示经过平滑后的激活值和权重。

基于灵敏度分析与异常值处理的低比特大模型量化方法及系统

技术领域

[0001] 本发明涉及大模型技术领域,尤其是一种基于灵敏度分析与异常值处理的低比特大模型量化方法及系统。

背景技术

[0002] 随着大模型参数规模激增至百亿、千亿级别,其巨大的存储需求和计算开销严重阻碍了在实际设备上的部署与应用。为了突破这一瓶颈,大模型压缩技术应运而生,其核心目标是在尽可能保持模型原有性能的前提下,显著减小模型体积、降低内存占用并加速推理过程。在众多压缩方法中(如知识蒸馏、模型剪枝等),大模型量化因其实现相对直接且效果显著而成为关键技术之一,它通过将模型权重和激活值从高精度浮点数(如FP32)转换为低精度表示(如INT8、FP16甚至更低),从根本上减少了存储需求和计算复杂度,是实现大模型轻量化与高效部署的关键突破口。然而,现有的量化方法存在一系列的客观缺点:

[0003] 1)、现有的量化方法对所有权重采用统一比特数(如8bit或4bit),未考虑不同权重对量化误差的敏感性差异,高敏感度权重(如深层MLP层的gate_proj)因低比特量化导致显著性能损失,而低敏感度权重(如注意力机制的o_proj)仍保留冗余精度,资源利用率低。2)、现有的量化方法对权重异常值缺乏抑制机制。权重矩阵在输入通道维度存在结构化的异常值,导致per-channel量化时缩放因子被异常值主导,这种长尾分布加剧量化误差,低比特量化时性能急剧劣化。并且在权重量化的过程中没有考虑层间输出偏差。3)、现有的量化方法处理激活的量化时,激活层(如k_proj激活)存在通道级离群值(幅值超正常值10倍)导致激活的量化难度显著高于权重,并且需要在运行时动态检测离群值,降低推理速度。

发明内容

[0004] 针对现有技术的不足,本发明提供一种基于灵敏度分析与异常值处理的低比特大模型量化方法及系统。

[0005] 本发明的技术方案为:基于灵敏度分析与异常值处理的低比特大模型量化方法,包括如下步骤:

[0006] S1)、利用基于灵敏度分析的层级混合精度量化策略将模型层划分为高、中、低敏感度层,并执行不同的量化操作;

[0007] S2)、利用基于两阶段联合的量化方法进行权重异常值抑制和权重逐层执行量化;

[0008] S3)、进行基于等价变换的激活离群值离线平滑处理。

[0009] 作为优选的,步骤S1)中,利用基于灵敏度分析的层级混合精度量化策略将模型层划分为高、中、低敏感度层,并执行不同的量化操作,具体包括如下步骤:

[0010] S11)、选取小型校准输入集X,通过前向传播记录模型各层输入激活与输出;

[0011] S12)、对第l层权重矩阵$W_l \in R^{m\times n}$,定义量化灵敏度$\Delta E \in R^{m\times n}$为原始权重预测值$W_l X$与量化权重预测值$W_l' X$之间的误差,其中,m、n分别为权重矩阵$W_l$的宽和高;

[0012] S13)、通过目标函数E(w)在局部点的扰动进行二阶泰勒展开量化灵敏度ΔE,忽略收敛模型的梯度项后得到:

[0013]
$$\Delta E \approx \frac{1}{2}\delta_w{}^T H \delta_w; \quad (1)$$
$$s.t.\quad e_q^T\delta_w + w_q - quant(w_q) = 0; \quad (2)$$

[0014] 式中,δ_w是权重量化引入的扰动值,H为Hessian矩阵;quant()是量化函数;e_q^T是在位置q为1其余位置为0的单位选择向量;w_q为w的第q个元素;w为模型的权重参数,即量化对象;T表示转置操作;

[0015] S14)、采用拉格朗日乘子法构建优化问题,即:

[0016] $$L = \frac{1}{2}\delta_w{}^T H \delta_w + \lambda(e_q^T\delta_w + w_q - quant(w_q)); \quad (3)$$

[0017] 通过$\frac{\partial L}{\partial \delta_w} = 0$,得到最优扰动:

[0018] $$\delta_w = -\frac{w_q - quant(w_q)}{[H^{-1}]_{qq}} H_{:,q}^{-1}; \quad (4)$$

[0019] 代入误差公式后,量化灵敏度解析式为:

[0020] $$\Delta E = \frac{1}{2}\frac{(w_q - quant(w_q))^2}{[H^{-1}]_{qq}}; \quad (5)$$

[0021] 式中,L表示拉格朗日函数;H^{-1}表示Hessian矩阵的逆,$[H^{-1}]_{qq}$表示H^{-1}的q行q列交叉位置的值;$H_{:,q}^{-1}$表示H^{-1}的第q列。

[0022] S15)、根据灵敏度评分将模型层划分为高、中、低敏感度层,采用如下量化策略计算缩放因子s和量化后的权重W_q;并通过量化后的权重W_q执行量化,不同的敏感度层采用不同的量化位数;其中:

[0023]
$$s = \frac{max(W_l) - min(W_l)}{2^b - 1}; \quad (6)$$
$$W_q = clamp(round(\frac{W_l}{s}), -2^{b-1} + 1, 2^{b-1} - 1); \quad (7)$$

[0024] 式中,clamp函数确保值不超出有效范围,round表示执行四舍五入取整操作;b是量化位数。

[0025] 作为优选的,步骤S1)中,所述校准输入集X的样本数量要求覆盖模型常见输入分布,Hessian矩阵的计算通过逐层前向传播与梯度回溯实现,忽略模型收敛后的梯度项$g^T\delta_w$,仅保留二阶项以简化计算。

[0026] 作为优选的,步骤S1)中,所述高、中、低敏感度层的划分阈值基于灵敏度评分的统计分布确定:灵敏度评分前30%的层为高敏感度层,中间40%为中敏感度层,后30%为低敏感度层;所述的clamp函数的取值范围为$(-2^{b-1}+1, 2^{b-1}-1)$用于避免量化后权重超出低精度整数的表示范围。

[0027] 作为优选的,步骤S2)中,两个阶段中的第一个阶段基于旋转不变性进行权重异常值抑制;第二个阶段采用基于逆Hessian矩阵减少层间量化误差。

[0028] 作为优选的,步骤S2)中,所述的第一个阶段采用随机选取与模型隐藏维度匹配的随机Hadamard矩阵对transformer块中的权重和块间激活进行转换,对于注意力层W_q、W_k、

W_v、及MLP层W_{gate}、W_{up}权重矩阵进行前乘$Q^{-1}*diag(\alpha)$；对W_o、W_{down}权重矩阵进行后乘Q，同时将RMSNorm线性部分融合至相邻权重，满足下式，使模型输出保持不变：

[0029] $RMSNorm(X_L)=RMSNorm(X_LQ^T)Q$； (8)

[0030] 式中，X_L为输入激活；Q为Hadamard矩阵。

[0031] 作为优选的，步骤S2)中，随机Hadamard矩阵Q满足$Q=QQ^T$且$QQ^T=I$。

[0032] 作为优选的步骤S2)中，所述的第二个阶段通过逐层执行量化，解决每一层的重构问题，对于线性层L的权重W_L、输入激活X_L，目标是找到相对于全精度层输出最小化平方误差的量化权重矩阵$\widehat{W}_L^*$，具体表达式为：

[0033] $\widehat{W}_L^* = argmin_{\widehat{W}_L}||W_LX_L - \widehat{W}_LX_L||_2^2$； （20）

[0034] 具体包括如下步骤：

[0035] S221)、初始化量化输出矩阵$Q \in R^{d_{row}\times d_{col}} = 0$，量化误差矩阵$E \in R^{d_{row}\times B} = 0$，B为块的大小；对逆Hessian矩阵$H^{-1}=(2X_LX_L^T+\lambda I)^{-1}$进行Cholesky分解：

[0036] $H^{-1}\leftarrow Cholesky(H^{-1})$； (21)

[0037] 其中，λ表示正则化参数；I表示单位矩阵；

[0038] S222)、按块大小B遍历权重矩阵的W_L的列；

[0039] 对当前块内每一列j∈[i,i+B-1]执行：

[0040] 量化操作：$Q_{:,j}\leftarrow quant(W_{L:,j})$； (22)

[0041] 误差计算：$E_{:,j-i} \leftarrow \frac{(W_{L:,j}-Q_{:,j})}{[H^{-1}]_{jj}}$； （23）

[0042] 式中，$Q_{:,j}$为W_L的第j列量化后的权重；$E_{:,j-i}$表示当前块内第(j-i)列的量化误差，i表示分块的起始索引(i=0,B,2B,…)；$[H^{-1}]_{jj}$表示逆Hessian矩阵的第j行j列交叉位置的值；

[0043] S223)、更新块内权重；

[0044] $W_{L_{:,j:(i+B)}} \leftarrow W_{L_{:,j:(i+B)}} - E_{:,j-i} * H^{-1}_{j,j:(i+B)}$； （24）

[0045] 式中，$W_{L_{:,j:(i+B)}}$表示权重矩阵W_L的第j列到第(i+B)列，即当前块内剩余的列；$E_{:,j-i}$表示当前块内第(j-i)列的量化误差；$H^{-1}_{j,j:(i+B)}$表示逆Hessian矩阵的第j行、第j列到(i+B)列的元素；

[0046] S224)、更新块间全局权重：

[0047] $W_{:,(i+B):} \leftarrow W_{:,(i+B):} - E * H^{-1}_{i,(i+B):}$； （25）

[0048] 式中，$W_{:,(i+B):}$表示第(i+B)列后面的权重块；$H^{-1}_{i,(i+B):}$表示逆Hessian矩阵的第i行、第(i+B)列之后的行向量。

[0049] 作为优选的，步骤S3)中，进行基于等价变换的激活离群值离线平滑处理，具体包括如下步骤：

[0050] S31)、通过校准数据前向推理，统计每个线性层的激活在Channel维度的绝对值最大值$max(|X_j|)^\infty$与权重在C_i维度的绝对值最大值$max(|W_j|)^{1-\infty}$，计算每通道平滑因子S_j；即：

[0051] $S_j = \frac{max(|X_j|)^{\alpha}}{max(|W_j|)^{1-\alpha}}, j = 1,2,\ldots,C_i;$ （26）

[0052] 式中,α表示缩放系数;S_j表示第j个通道的平滑因子;X_j表示第j个通道的激活值;W_j表示第j个通道的权重;

[0053] S32)、通过将通道平滑因子S_j嵌入前序模块RMSNorm参数,在RMSNorm模块权重中除以S_j;

[0054] 在W_q、W_k、W_v、W_{gate}、W_{up}的线性层权重中乘以S_j,实现激活离群值向权重的迁移,保持线性层输出与原输出等价,即:

[0055] $Y = (Xdiag(S)^{-1}) \cdot (diag(S)W) = \hat{X}\hat{W};$ （27）

[0056] 式中,Y为线性层输出;S为通道平滑因子;X表示该线性层的激活值,W表示该线性层的权重;$\hat{X}$和$\hat{W}$分别表示经过平滑后的激活值和权重。

[0057] 本发明的有益效果为:

[0058] 1、本发明基于灵敏度分析的层级混合精度量化策略识别对量化误差敏感的关键权重,从而在量化过程中采用差异化策略,保留高灵敏度权重的精度并且对低灵敏度权重实施更激进量化,以最小化模型性能损失,差异化量化使低比特场景下模型性能损失降低30%以上;

[0059] 2、本发明两阶段权重量化协同解决异常值与误差累积问题:Hadamard变换使权重长尾分布转为均匀分布,量化误差降低40%;逆Hessian优化使深层网络的误差累积减少50%;

[0060] 3、本发明离线地将量化难度从激活迁移到权重,提高激活量化的友好性,并且无需在运行时动态检测离群值,避免影响推理速度;推理速度提升15%-20%;适用于端侧实时推理;敏感度层采用2bit量化,模型存储量较8bit量化进一步压缩4倍,内存占用降低75%,硬件资源消耗更少。

附图说明

[0061] 图1为本发明方法的流程示意图;

[0062] 图2为本发明实施例中LLaMA-7B最后一层q_proj、k_proj权重分布图;

[0063] 图3为本发明实施例最后一层q_proj、k_proj权重灵敏度热力图;

[0064] 图4为本发明实施例模型不同层深度与层类型的量化误差曲线图;

[0065] 图5为本发明实施例插入随机Hadamard矩阵的模型结构图;

[0066] 图6为本发明实施例最后一层k_proj平滑前后的权重与激活绝对值分布图。

具体实施方式

[0067] 下面结合附图对本发明的具体实施方式作进一步说明:

[0068] 如图1所示,本实施例提供一种基于灵敏度分析与异常值处理的低比特大模型量化方法,包括如下步骤:

[0069] S1)、利用基于灵敏度分析的层级混合精度量化策略将模型层划分为高、中、低敏感度层,并执行不同的量化操作;具体包括如下步骤:

[0070] S11)、选取小型校准输入集X,通过前向传播记录模型各层输入激活与输出;

[0071] S12)、对第l层权重矩阵$W_l \in R^{m\times n}$,定义量化灵敏度$\Delta E \in R^{m\times n}$为原始权重预测值$W_l X$与量化权重预测值$W_l' X$之间的误差;

[0072] S13)、通过目标函数E(w)在局部点的扰动进行二阶泰勒展开量化灵敏度ΔE,忽略收敛模型的梯度项后得到:

[0073]
$$\Delta E = ||W_l' X - W_l X|| = E(w+\delta_w) - E(w) = g^T \delta_w + \frac{1}{2}\delta_w{}^T H \delta_w + O(||\delta_w||^3) \approx \frac{1}{2}\delta_w{}^T H \delta_w; \quad (1)$$

$$s.t. \quad e_q^T \delta_w + w_q - quant(w_q) = 0; \quad (2)$$

[0074] 式中,δ_w是权重量化引入的扰动值,H为Hessian矩阵;quant()是量化函数;e_q^T是在位置q为1其余位置为0的单位选择向量;w_q为w的第q个元素;w为模型的权重参数,即量化对象;T表示转置操作;W_l'表示量化后的权重;g表示目标函数的一阶导数;O表示高阶无穷小项;

[0075] S14)、采用拉格朗日乘子法构建优化问题,即:

[0076]
$$L = \frac{1}{2}\delta_w{}^T H \delta_w + \lambda(e_q^T \delta_w + w_q - quant(w_q)); \quad (3)$$

[0077] 通过$\frac{\partial L}{\partial \delta_w} = 0$,得到最优扰动:

[0078]
$$\delta_w = -\frac{w_q - quant(w_q)}{[H^{-1}]_{qq}} H_{:,q}^{-1}; \quad (4)$$

[0079] 代入误差公式后,量化灵敏度解析式为:

[0080]
$$\Delta E = \frac{1}{2}\frac{(w_q - quant(w_q))^2}{[H^{-1}]_{qq}}; \quad (5)$$

[0081] 式中,L表示拉格朗日函数;H^{-1}表示Hessian矩阵的逆,$[H^{-1}]_{qq}$表示H^{-1}的q行q列交叉位置的值;$H_{:,q}^{-1}$表示H^{-1}的第q列。

[0082] S15)、根据灵敏度评分将模型层划分为高、中、低敏感度层,采用如下量化策略计算缩放因子s和量化后的权重W_q;并通过量化后的权重W_q执行量化,不同的敏感度层采用不同的量化位数;其中:

[0083]
$$s = \frac{max(W_l) - min(W_l)}{2^b - 1}; \quad (6)$$

$$W_q = clamp(round(\frac{W_l}{s}), -2^{b-1}+1, 2^{b-1}-1); \quad (7)$$

[0084] 式中,clamp函数确保值不超出有效范围,round表示执行四舍五入取整操作;b是量化位数,对于高敏感度层采用b=8比特量化,对于中敏感层采用b=4比特量化,对于低敏感层采用b=2比特量化。

[0085] 如图2所示,左图和右图分别为q_proj、k_proj权重;从输出通道视角观察,在部分输入通道维度上对应的权重绝对值较大。由于权重量化采用per-channel策略,每个输出通道独立分配缩放因子,输入通道维度的异常值会直接影响量化效果。

[0086] 图3展示了最后一层的q_proj和k_proj权重灵敏度热力图;左图为q_proj灵敏度,右图为k_proj灵敏度;热力图颜色越深,灵敏度越高(ΔE越大),表示该位置权重对量化误差越敏感,需保留更高精度;q_proj的输入通道2000-3000区间、k_proj的输入通道1000-

1500区间灵敏度最高,需采用更高比特量化。

[0087] 图4展示了不同层类型与深度的量化误差分布,层类型差异体现在MLP层的gate_proj、up_proj、down_proj权重对量化更敏感,而注意力输出投影权重self_attn.o_proj的灵敏度较低;层深度效应体现在从第16层开始,量化误差显著上升,这与深层网络中权重量化误差的累积放大效应有关。

[0088] S2)、利用基于两阶段联合的量化方法进行权重异常值抑制和权重逐层执行量化;

[0089] 其中,两个阶段中的第一个阶段基于旋转不变性进行权重异常值抑制;第二个阶段采用基于逆Hessian矩阵减少层间量化误差。

[0090] 所述的第一个阶段选取与模型隐藏维度匹配的随机Hadamard矩阵对transformer块中的权重和块间激活进行转换,将RMSNorm的线性部分融合到相邻的权重矩阵中;同时,选择一个大小与隐藏维度匹配的随机Hadamard矩阵Q;

[0091] 如图5所示,对于注意力层W_q、W_k、W_v、及MLP层W_{gate}、W_{up}权重矩阵进行前乘$Q^{-1}*diag(\alpha)$;对W_o、W_{down}权重矩阵进行后乘Q,同时将RMSNorm线性部分融合至相邻权重,满足下式,使模型输出保持不变:

[0092] $RMSNorm(X_L)=RMSNorm(X_LQ^T)Q$; (8)

[0093] $W_q \leftarrow Q^{-1}*diag(\alpha)*W_q$; (9)

[0094] $W_k \leftarrow Q^{-1}*diag(\alpha)*W_k$; (10)

[0095] $W_v \leftarrow Q^{-1}*diag(\alpha)*W_v$; (11)

[0096] $W_o \leftarrow W_o*Q$; (12)

[0097] $W_{gate} \leftarrow Q^{-1}*diag(\alpha)*W_{gafe}$; (13)

[0098] $W_{up} \leftarrow Q^{-1}*diag(\alpha)*W_{up}$; (14)

[0099] $W_{down} \leftarrow W_{down}*Q$; (15)

[0100] 式中,W_q、W_k、W_v分别为注意力层的q、k、v权重矩阵;W_{gate}、W_{up}、W_{down}分别表示gate_proj、up_proj、down_proj权重矩阵;diag(α)表示RMSNorm的缩放因子α构成的对角矩阵,将其吸收到相邻的权重矩阵中;X_L为输入激活;Q为Hadamard矩阵;W_o是输出投影权重;Q^{-1}为逆Hadamard矩阵;

[0101] 在标准Transformer结构中,注意力输出的计算可表示为:

[0102] $Y = concat[P_1V_1,\ldots,P_{n_h}V_{n_h}]\,W_o = \sum_{h=1}^{H} P_h X_L W_v^{(h)} W_o^{(h)}$; (16)

[0103] 式中,Y为标准Transformer结构中注意力层的最终输出;P_h是注意力分数矩阵;$V_h = XW_v^{(h)}$是第h个头的值向量;

[0104] 值向量V_h和输出投影权重W_o的矩阵乘法在量化时易受异常值影响,导致低精度量化误差显著;通过头级哈达玛变换保持输出不变;即:

[0105]
$$\widetilde{W_v^{(h)}} = W_v^{(h)} * H_{d_h}; \quad (17)$$
$$\widetilde{W_o^{(h)}} = H_{d_h} * W_o^{(h)}; \quad (18)$$

[0106] $\tilde{Y} = \sum_{h=1}^{H} P_h X_L \widetilde{W_v^{(h)}}\,\widetilde{W_o^{(h)}} = \sum_{h=1}^{H} P_h X_L (W_v^{(h)} H_{d_h})(H_{d_h} W_o^{(h)}) = Y$; (19)

[0107] 式中,$W_v^{(h)}$表示第h个注意力头的值向量投影权重矩阵;$\widetilde{W_v^{(h)}}$表示$W_v^{(h)}$进行哈达

玛变换后的结果；$W_o^{(h)}$为第h个注意力头的输出投影权重矩阵；$\widetilde{W_o^{(h)}}$为$W_o^{(h)}$进行哈达玛变换后的结果；H_{d_h}为哈达玛矩阵；$\tilde{Y}$为Transformer结构中注意力层进行哈达玛变换后的最终输出，与原始输出的结果Y保持不变。

[0108] 由于哈达玛矩阵H_{d_h}满足$H_{d_h}=H_{d_h}{}^T$，$H_{d_h}H_{d_h}{}^T=I$，所以通过头级哈达玛变换保持输出不变。此变换将异常值分散到整个向量空间，从长尾分布转换为均匀分布，可以无缝集成到注意力模块中。

[0109] 所述的第二个阶段通过逐层执行量化，解决每一层的重构问题，对于线性层L的权重W_L、输入激活X_L，目标是找到相对于全精度层输出最小化平方误差的量化权重矩阵$\widehat{W}_L{}^*$，具体表达式为：

[0110] $$\widehat{W}_L{}^*=argmin_{\widehat{W}_L}||W_LX_L-\widehat{W}_LX_L||_2^2; \quad (20)$$

[0111] 具体包括如下步骤：

[0112] S221)、初始化量化输出矩阵$Q\in R^{d_{row}\times d_{col}}=0$，量化误差矩阵$E\in R^{d_{row}\times B}=0$，B为块的大小；对逆Hessian矩阵$H^{-1}=(2X_LX_L{}^T+\lambda I)^{-1}$进行Cholesky分解：

[0113] $$H^{-1}\leftarrow Cholesky(H^{-1}); \quad (21)$$

[0114] 其中，λ表示正则化参数；I表示单位矩阵；

[0115] S222)、按块大小B遍历权重矩阵的W_L的列；

[0116] 对当前块内每一列j∈[i,i+B-1]执行：

[0117] 量化操作：$Q_{:,j}\leftarrow quant(W_{L:,j})$； (22)

[0118] 误差计算：$E_{:,j-i}\leftarrow\frac{(W_{L:,j}-Q_{:,j})}{[H^{-1}]_{jj}}$； (23)

[0119] 式中，$Q_{:,j}$为W_L的第j列量化后的权重；$E_{:,j-i}$表示当前块内第(j-i)列的量化误差，i表示分块的起始索引(i＝0,B,2B,…)；$[H^{-1}]_{jj}$表示逆Hessian矩阵的第j行j列交叉位置的值；$W_{L:,j}$为权重矩阵W_L的第j列；

[0120] S223)、更新块内权重；

[0121] $$W_{L:,j:(i+B)}\leftarrow W_{L:,j:(i+B)}-E_{:,j-i}*H^{-1}_{j,j:(i+B)}; \quad (24)$$

[0122] 式中，$W_{L:,j:(i+B)}$表示权重矩阵W_L的第j列到第(i+B)列，即当前块内剩余的列；$E_{:,j-i}$表示当前块内第(j-i)列的量化误差；$H^{-1}_{j,j:(i+B)}$表示逆Hessian矩阵的第j行、第j列到(i+B)列的元素；

[0123] S224)、更新块间全局权重：

[0124] $$W_{:,(i+B):}\leftarrow W_{:,(i+B):}-E*H^{-1}_{i,(i+B):}; \quad (25)$$

[0125] 式中，$W_{:,(i+B)}$：表示第(i+B)列后面的权重块；$H^{-1}_{i,(i+B):}$表示逆Hessian矩阵的第i行、第(i+B)列之后的行向量。

[0126] 在实现的过程中，先将权重分组为多个block，对某个block内的所有参数逐列量化，每个参数量化后，需要适当调整这个block内其他未量化的参数，以弥补量化造成的精度损失。对当前block内各权重列依次执行量化、误差计算及内部权重更新；完成当前block

内部的量化后,再使用当前block的误差矩阵更新后续所有权重块。

[0127] S3)、进行基于等价变换的激活离群值离线平滑处理;具体包括如下步骤:

[0128] S31)、通过校准数据前向推理,统计每个线性层的激活在Channel维度的绝对值最大值$\max(|X_j|)^{\alpha}$与权重在C_i维度的绝对值最大值$\max(|W_j|)^{1-\alpha}$,计算每通道平滑因子S_j;即:

[0129] $$S_j = \frac{max(|X_j|)^{\alpha}}{max(|W_j|)^{1-\alpha}}, j = 1,2,\ldots,C_i; \quad (26)$$

[0130] 式中,α表示缩放系数;S_j表示第j个通道的平滑因子;X_j表示第j个通道的激活值;W_j表示第j个通道的权重;

[0131] S32)、通过将通道平滑因子S_j嵌入前序模块RMSNorm参数,在RMSNorm模块权重中除以S_j;

[0132] 在W_q、W_k、W_v、W_{gate}、W_{up}的线性层权重中乘以S_j,实现激活离群值向权重的迁移,保持线性层输出与原输出等价,即:

[0133] $$Y = (Xdiag(S)^{-1}) \cdot (diag(S)W) = \hat{X}\hat{W}; \quad (27)$$

[0134] 式中,Y为线性层输出;S为通道平滑因子;X表示该线性层的激活值,W表示该线性层的权重;$\hat{X}$和$\hat{W}$分别表示经过平滑后的激活和权重。

[0135] 如图6所示,上图为平滑前后的权重分布(幅值均匀),下图为平滑前后激活分布(离群值消失);平滑因子使激活分布最大值从12降至1.2(降低90%),同时权重幅值仅从0.4升至4(增大10倍)。激活异常值被有效迁移至权重层,使得平滑后的激活分布更接近理想量化区间,同时权重层仍保持平滑特性。

[0136] 上述实施例和说明书中描述的只是说明本发明的原理和最佳实施例,在不脱离本发明精神和范围的前提下,本发明还会有各种变化和改进,这些变化和改进都落入要求保护的本发明范围内。

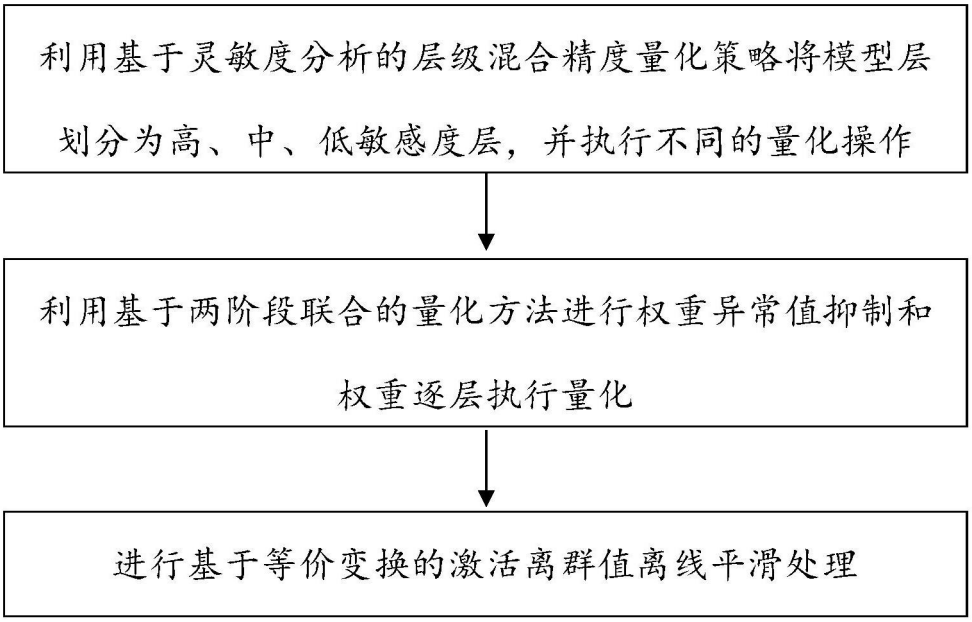
利用基于灵敏度分析的层级混合精度量化策略将模型层划分为高、中、低敏感度层，并执行不同的量化操作
利用基于两阶段联合的量化方法进行权重异常值抑制和权重逐层执行量化
进行基于等价变换的激活离群值离线平滑处理

图1

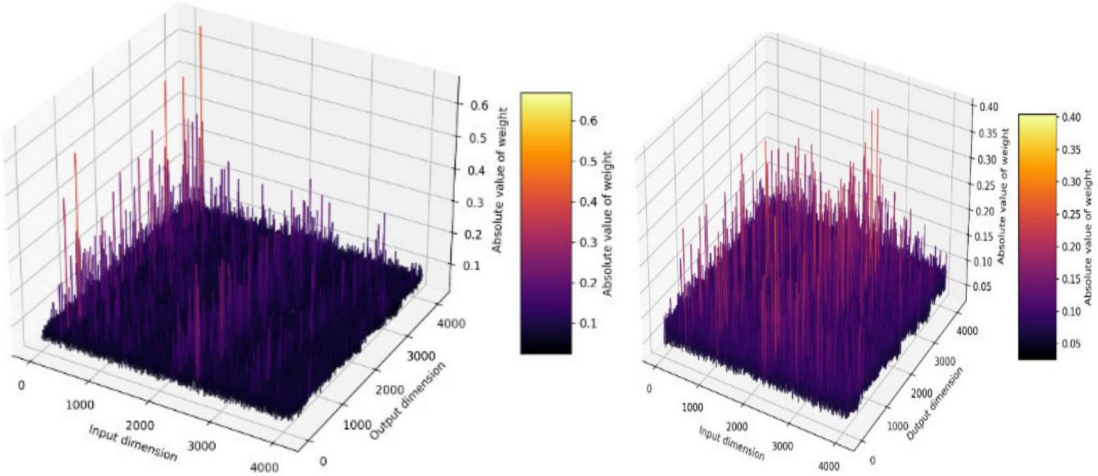
Absolute value of weight
Input dimension
Output dimension
Absolute value of weight
Input dimension
Output dimension

图2

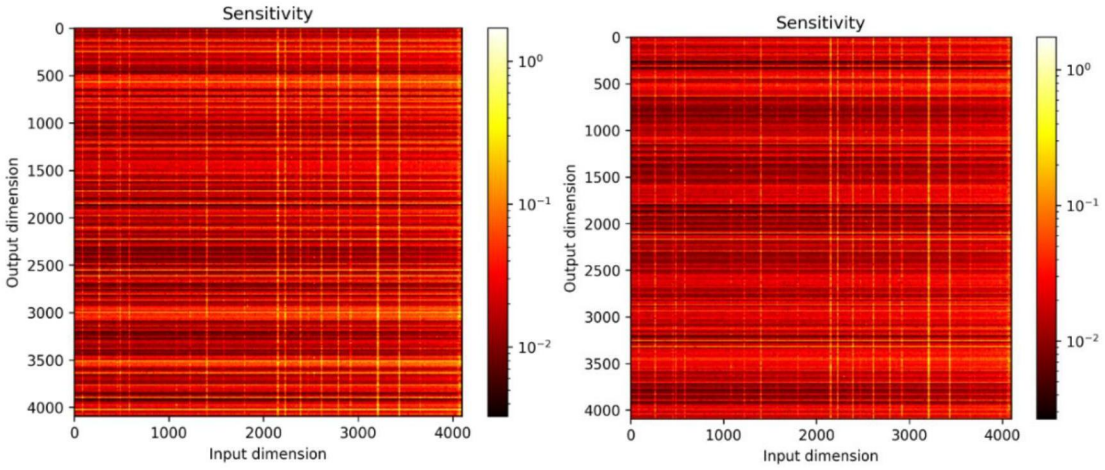
Sensitivity
Output dimension
Input dimension
Sensitivity
Output dimension
Input dimension

图3

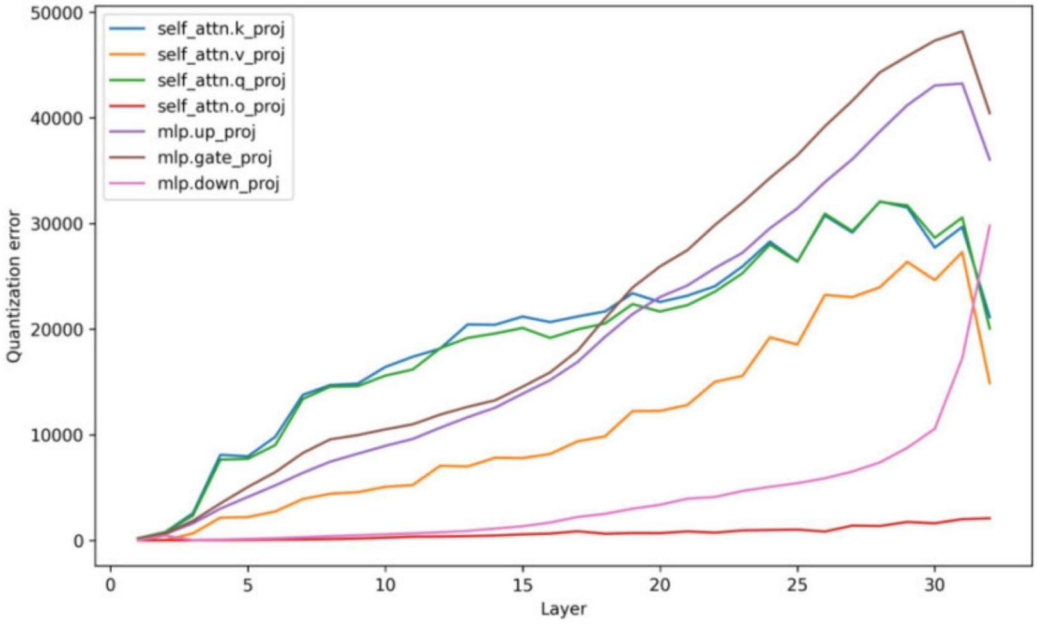
self_attn.k_proj
self_attn.v_proj
self_attn.q_proj
self_attn.o_proj
mlp.up_proj
mlp.gate_proj
mlp.down_proj
Quantization error
Layer

图4

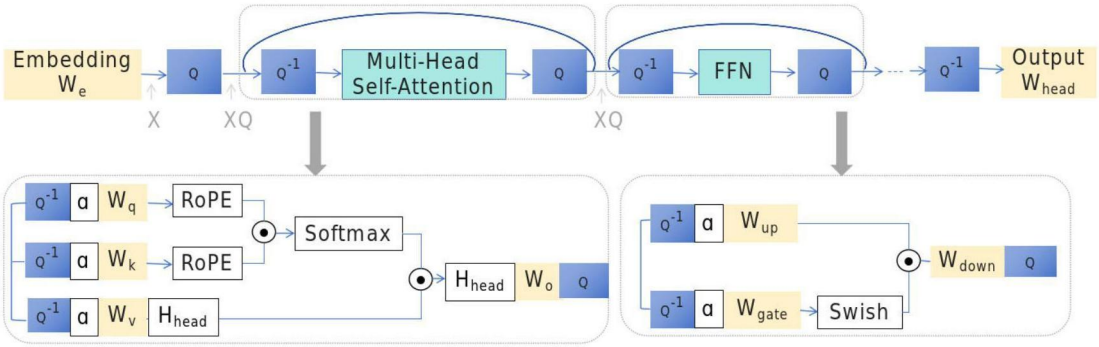
Embedding
W_e
Q
Q^{-1}
Multi-Head
Self-Attention
Q
Q^{-1}
FFN
Q
Q^{-1}
Output
W_{head}
X
XQ
XQ
Q^{-1}
α
W_q
RoPE
Q^{-1}
α
W_k
RoPE
Softmax
Q^{-1}
α
W_v
H_{head}
H_{head}
W_o
Q
Q^{-1}
α
W_{up}
Q^{-1}
α
W_{gate}
Swish
W_{down}
Q

图5

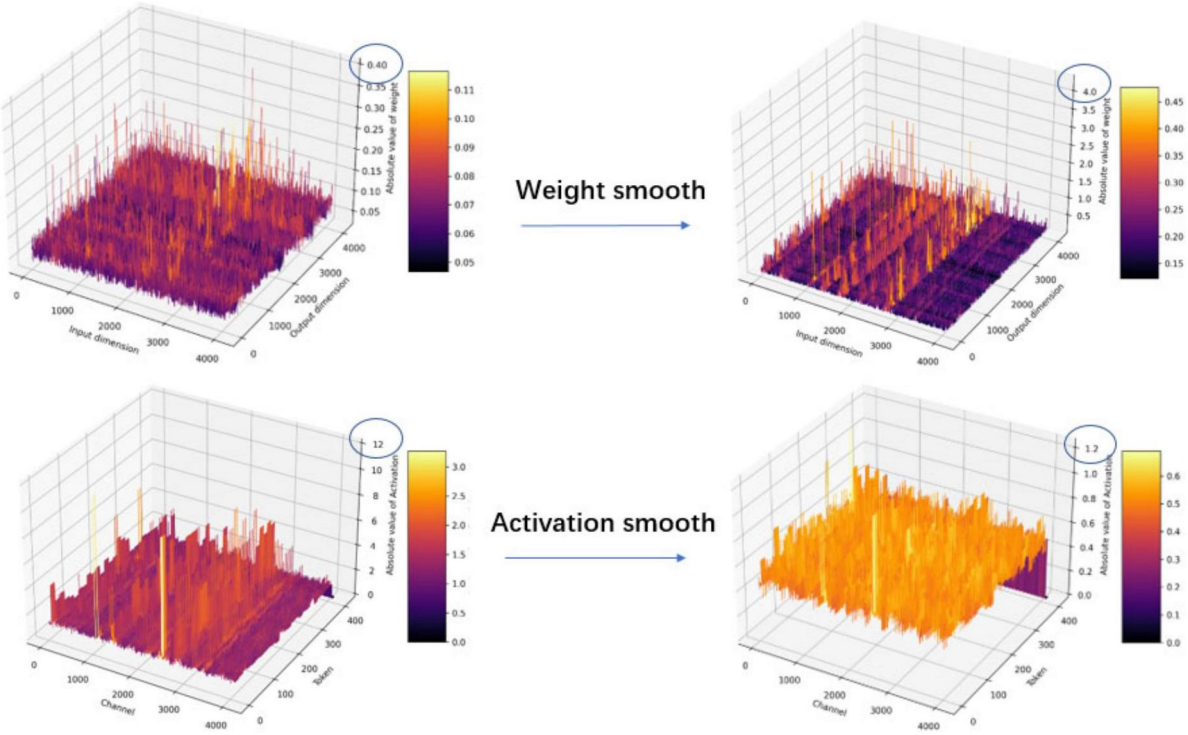
Weight smooth
Input dimension
Output dimension
Absolute value of weight
Activation smooth
Channel
Token
Absolute value of Activation

图6